

VILNIAUS UNIVERSITETAS
MATEMATIKOS IR INFORMATIKOS FAKULTETAS
INFORMATIKOS INSTITUTAS
INFORMATIKOS KATEDRA

Kursinis darbas

Neuroninių tinklų apmokymas su triukšmu
(Neural Network Training with Noise)

Atliko: 4 kurso 2 grupės studentė

Gabrielė Rinkevičiūtė (parašas)

Darbo vadovas:

Asist. Dr. Linas Litvinas (parašas)

Vilnius
2025

Turinys

1. Ataskaitos	2
1.1. Dirbtinio neuroninio tinklo rezultatai	2
1.1.1. Sferos funkcija.....	2
1.1.1.1. Švarūs duomenys	2
1.1.1.2. Triukšmingi duomenys	3
1.1.1.3. Palyginimas	3
1.2. K artimiausių kaimynų metodo rezultatai.....	3
1.2.1. Sferos funkcija, kai $k = 1$	4
1.2.1.1. Švarūs duomenys	4
1.2.1.2. Triukšmingi duomenys	4
1.2.1.3. Palyginimas	5
1.2.2. Sferos funkcija, kai $k = 3$	5
1.2.2.1. Švarūs duomenys	5
1.2.2.2. Triukšmingi duomenys	5
1.2.2.3. Palyginimas	5
1.2.3. K artimiausių kaimynų metodo rezultatų palyginimas	6
Išvadas	7
2. Dirbtinių neuroninių tinklų pritaikymas	8
2.1. Klasifikavimas.....	8
2.2. Regresija	8
3. Dirbtinių neuroninių tinklų sandara	9
3.1. Neuronai	9
3.1.1. Svertinės sumos funkcija.....	10
3.1.2. Aktyvavimo funkcijos.....	10
3.1.2.1. Sigmoidinė funkcija	10
3.1.2.2. Hiperbolinio tangento funkcija.....	10
3.1.2.3. Rektifikuoto tiesinio elemento funkcija	10
3.2. Sluoksniai dirbtiniuose neuroniniuose tinkluose	11
3.2.1. Įvesties sluoksnis	11
3.2.2. Išvesties sluoksnis	11
3.2.3. Paslėptasis sluoksnis	12
4. Duomenų aibės kūrimas	13
4.1. Dirbtinis duomenų generavimas	13
4.1.1. Sferos funkcija.....	13
4.2. Triukšmo duomenų aibei pritaikymas.....	14
4.2.1. Gauso skirstinio metodas	14
Išvados	17

1. Ataskaitos

Prieš pereinant prie vėlesniuose skyreliuose aptariamų tyrimų ir juose rastų rezultatų, pravartu aptarti juose vartojamas sąvokas. Šio darbo kontekste laikysime, kad „epocha“ tai yra modelio perėjimas per visą apmokymo duomenų aibę, o „iteracija“ yra modelio svertų atnaujinimas.

1.1. Dirbtinio neuroninio tinklo rezultatai

Tyrimas buvo atliktas su 1 000, 10 000, 100 000 ir 1 000 000 taškų aibėmis, kurių 70% buvo skiriami modelio apmokymui, 15% - modelio validavimui ir kiti 15% - modelio testavimui.

Bandymui buvo generuojami keturmačiai duomenys ($n = 4$), kurių kiekviena komponentė buvo atsitiktinai parenkama iš intervalo $[-5; 5]$. Prieš apmokant modelį, duomenys buvo papildomai apdorojami: kiekviena vektoriaus komponentė bei sferos funkcijos reikšmės buvo normalizuojamos naudojant min–max metodą.

Pats neuroninio tinklo modelis buvo sudarytas iš vieno įvesties, vieno paslėpto ir vieno išvesties sluoksnių. Kiekvienas iš šių sluoksnių susidėjo iš atitinkamai 4, 70, ir 1 neuronų. Paslėptame sluoksnyje buvo taikoma zigmoidinė aktyvavimo funkcija, tuo tarpu išvesties sluoksnyje buvo palikta tiesinė aktyvavimo funkcija. Bandymo metu buvo pastebėta, kad geriausius rezultatus sukurtas modelis pasiekia, kai mokymosi greitis yra 0,01. Modelis buvo apmokomas padalinus apmokymo taškų aibę į dalis po 8 taškus.

Visais atvejais prieš skaičiuojant statistinius absoliutinės paklaidos rodiklius, modelio spėjimai buvo konvertuoti į originalų duomenų mastelį. Taigi atsižvelgus, kad tyrimo metu duomenys buvo apibrėžiami sferos funkcija, maksimali galima absoliutinė paklaida šio tyrimo atveju yra 100.

Modelio apmokymo etapo ilgis buvo stabdomas įvykus vienai iš stabdymo sąlygų:

- klaidos funkcijos reikšmė 13 epochų iš eilės mažėja mažiau nei per 10^{-6} ;
- buvo pasiektas maksimalus 150 epochų kiekis.

1.1.1. Sferos funkcija

1.1.1.1. Švarūs duomenys

Šiame bandyme buvo tiriamas neuroninio tinklo gebėjimas interpoliuoti švarius duomenis, kurie pasižymi sferos funkcijos (1 lygtis) savybėmis.

Taškų kiekis	Minimumas	Maksimumas	Vidurkis	Standartinis nuokrypis
1 000	0.002857	6.881401	1.773480	1.231157
10 000	0.001137	4.690506	0.625588	0.514914
100 000	0.000001	1.170944	0.217896	0.172228
1 000 000	0.000004	1.631981	0.416016	0.274041

1 lentelė. Dirbtinio neuroninio tinklo absoliutinės paklaidos statistiniai rodikliai nagrinėjant sferos funkciją

Matome, kad didinant taškų kiekį nuo 1 000 iki 100 000, modelio daromų paklaidų vidurkis ir standartinis nuokrypis mažėjo, taigi galime teigti, kad modelio tikslumas didėjo. Tačiau verta atkreipti dėmesį, kad padidinus taškų aibės dydį iki 1 000 000 modelio paklaidų statistiniai rodikliai pablogėjo.

1.1.1.2. Triukšmingi duomenys

Šiame bandyme buvo tiriamas neuroninio tinklo gebėjimas interpoliuoti duomenis, kurie pasižymi sferos funkcijos (1 lygtis) savybėmis jiems pridėjus triukšmo.

Taškų kiekis	Minimumas	Maksimumas	Vidurkis	Standartinis nuokrypis
1 000	0.008972	9.575722	1.970832	1.910026
10 000	0.000362	5.672182	2.127527	1.227688
100 000	0.000038	2.539330	0.536711	0.420499
1 000 000	0.000006	1.809952	0.419722	0.278947

2 lentelė. Dirbtinio neuroninio tinklo absoliutinės paklaidos statistiniai rodikliai nagrinėjant sferos funkciją su triukšmu

Iš 2 lentelės matoma, kad bendru atveju vidurkis didinant taškų kiekį mažėja. Atskiras atvejis yra, kai taškų kiekis buvo padidintas iki 10 000 - tuo atveju absoliutinės paklaidos vidurkis padidėjo.

1.1.1.3. Palyginimas

Matome, kad modelio absoliutinės paklaidos vidurkis arba ženkliai nesikeitė, arba paklaidos vidurkio padidėjimas svyravo nuo 1.1 iki 3.4 kartų. Standartinio nuokrypis taip pat arba nerodė didelių pakitimų, arba paklaidos standartinio nuokrypio padidėjimas svyravo nuo 1.6 iki 2.4.

1.2. K artimiausių kaimynų metodo rezultatai

Tyrimas buvo atliktas su 1 000, 10 000, 100 000, 1 000 000 ir 10 000 000 taškų aibėmis, kurių 85% buvo skiriami modelio apmokymui ir validavimui, likę 15% - modelio testavimui.

Bandymui buvo generuojami keturmačiai duomenys ($n = 4$), kurių kiekviena komponentė buvo atsitiktinai parenkama iš intervalo $[-5; 5]$. Prieš apmokant modelį, duomenys buvo papildomai apdorojami: kiekviena vektoriaus komponentė bei sferos funkcijos reikšmės buvo normalizuojamos naudojant min–max metodą.

Modelis buvo validuojamas pasitelkiant kryžminę validaciją (angl. „cross-validation“). Bandymų metu buvo nustatyta, kad geriausiai modelis veikia, kai kaimynų skaičius yra lygus 3, tačiau palyginimui buvo atlikti bandymai ir kai artimiausias kaimynas yra vienas.

Visais atvejais prieš skaičiuojant statistinius absoliutinės paklaidos rodiklius, modelio spėjimai buvo konvertuoti į originalų duomenų mastelį. Taigi atsižvelgus, kad tyrimo metu duomenys buvo apibrėžiami sferos funkcija, maksimali galima absoliutinė paklaida šio tyrimo atveju yra 100.

1.2.1. Sferos funkcija, kai $k = 1$

1.2.1.1. Švarūs duomenys

Šiame bandyme buvo tiriamas K artimiausių kaimynų metodo gebėjimas interpoliuoti duomenis, kurie pasižymi sferos funkcijos savybėmis. Šiuo atveju $k = 1$.

Taškų kiekis	Minimumas	Maksimumas	Vidurkis	Standartinis nuokrypis
1 000	0.050320	20.178803	5.182272	3.617230
10 000	0.002558	13.502786	2.975179	2.329911
100 000	0.000256	11.192788	1.698232	1.322762
1 000 000	0.000007	6.239792	0.959560	0.743995
10 000 000	0.00000049	3.839611	0.538008	0.413742

3 lentelė. K artimiausių kaimynų metodo absoliutinės paklaidos statistiniai rodikliai nagrinėjant sferos funkciją ($k = 1$)

1.2.1.2. Triukšmingi duomenys

Šiame bandyme buvo tiriamas K artimiausių kaimynų metodo gebėjimas interpoliuoti duomenis, kurie pasižymi sferos funkcijos savybėmis, jiems pridėjus triukšmo. Šiuo atveju $k = 1$.

Taškų kiekis	Minimumas	Maksimumas	Vidurkis	Standartinis nuokrypis
1 000	0.028075	20.031243	5.220319	3.692268
10 000	0.007079	14.064025	2.997375	2.348190
100 000	0.000221	10.859588	1.743053	1.354251
1 000 000	0.000006	6.902217	1.042092	0.800102
10 000 000	0.000000	4.408415	0.670634	0.510044

4 lentelė. K artimiausių kaimynų metodo absoliutinės paklaidos statistiniai rodikliai nagrinėjant sferos funkciją ($k = 1$)

1.2.1.3. Palyginimas

Iš pateiktų 3 ir 4 lentelių matome, kad pridėjus triukšmą k artimiausių kaimynų interpoliacijos rezultatų tikslumas žymiai nesikeitė. Didžiausias absoliutinės paklaidos vidurkio padidėjimas siekia 1,2 karto. Tokias pačias išvalgas galima padaryti ir nagrinėjant standartinį nuokrypį.

1.2.2. Sferos funkcija, kai $k = 3$

1.2.2.1. Švarūs duomenys

Šiame bandyme buvo tiriamas K artimiausių kaimynų metodo gebėjimas interpoliuoti duomenis, kurie pasižymi sferos funkcijos savybėmis. Šiuo atveju $k = 3$.

Taškų kiekis	Minimumas	Maksimumas	Vidurkis	Standartinis nuokrypis
1 000	0.051417	22.357332	4.055465	3.877167
10 000	0.001065	12.780683	2.314161	1.924742
100 000	0.000089	10.150919	1.240283	1.036862
1 000 000	0.000011	5.804630	0.677661	0.562266
10 000 000	0.0000001	3.9141042	0.373981	0.306836

5 lentelė. K artimiausių kaimynų metodo absoliutinės paklaidos statistiniai rodikliai nagrinėjant sferos funkciją ($k = 3$)

1.2.2.2. Triukšmingi duomenys

Šiame bandyme buvo tiriamas K artimiausių kaimynų metodo gebėjimas interpoliuoti duomenis, kurie pasižymi sferos funkcijos savybėmis. Šiuo atveju $k = 3$.

Taškų kiekis	Minimumas	Maksimumas	Vidurkis	Standartinis nuokrypis
1 000	0.030330	22.659118	4.040047	3.888274
10 000	0.001735	12.557448	2.314843	1.926788
100 000	0.000121	10.204885	1.263033	1.047999
1 000 000	0.000002	5.948286	0.718320	0.585065
10 000 000	0.00000008	4.096856	0.442222	0.348677

6 lentelė. K artimiausių kaimynų metodo absoliutinės paklaidos statistiniai rodikliai nagrinėjant sferos funkciją ($k = 3$)

1.2.2.3. Palyginimas

Iš aukščiau esančių 5 ir 6 lentelių galima pamatyti, kad taikant artimiausių kaimynų metodą, kai $k = 3$ tikslumas mažėja neženkiai - didžiausias absoliutinės paklaidos vidurkio padidėjimas siekia 1,2 karto. Standartinio nuokrypis padidėja iki 1,1 karto.

1.2.3. K artimiausių kaimynų metodo rezultatų palyginimas

Palyginus metodo rezultatus, kai $k = 1$ ir $k = 3$ yra akivaizdu, kad su didesniu kaimynų kiekiu, modelis grąžina geresnius rezultatus. Taip pat matome, kad abiem atvejais, modelių grąžinami rezultatai stabiliai gerėjo.

Įvadas

TODO

Tikslas. TODO: tikslas

Uždaviniai.

1. TODO: uždavinys 1
2. TODO: uždavinys 2
3. TODO: uždavinys 3

2. Dirbtinių neuroninių tinklų pritaikymas

Dirbtiniai neuroniniai tinklai (angl. „Artificial Neural Networks“) - mašininio mokymosi sritis, apimanti skaitinius modelius, pasižyminčius sluoksniu architektūra (angl. „layered architecture“) bei savarankišku mokymusi, siekiant nustatyti matematinę sąryšį tarp duomenų įvesties ir numatytos išvesties. Kadangi dirbtiniai neuroniniai tinklai taip pat pasižymi netiesiškumu ir sugebėjimu apibendrinti duomenis, šie modeliai yra tinkami naudoti užduotyse, reikalaujančiose sudėtingų raštų (angl. „pattern“) atpažinimo. Šios užduotys dažniausiai yra skirstomos į dvi rūšis: klasifikavimą ir regresiją. Daugiau apie kiekvieną iš jų galima rasti atitinkamai 2.1 ir 2.2 poskyriuose.

Šio kursinio projektinio darbo metu buvo pasirinkta spręsti regresijos problemą, siekiant įvertinti dirbtinių neuroninių tinklų apmokymo sąlygas, kai mokymosi duomenys nėra visiškai tikslūs ir turi triukšmo.

2.1. Klasifikavimas


Klasifikavimas - užduotis, kurioje modelis iš numatytos diskrečios aibės turi kiekvienam duomenų įrašui priskirti vieną ar kelias reikšmes. Pavyzdžiui, klasifikavimo uždavinio pavyzdžiu galėtų būti klasių „katė“ arba „šuo“ priskyrimas pateiktoms nuotraukoms. Kitas pavyzdys galėtų būti augalo rūšies nustatymas pagal duotus konkretaus objekto parametrus: žiedo spalvą, lapų matmenis ir pan.

2.2. Regresija

Regresijos problemą sprendžiantys modeliai yra susitelkę ties tolydžios reikšmės nustatymu. Šio tipo uždavinių pavyzdžiai yra finansų rinkos statistinių rodiklių nuspėjimas, temperatūros prognozė, remiantis istoriniais duomenimis ir t.t.

3. Dirbtinių neuroninių tinklų sandara

Dirbtiniai neuroniniai tinklai yra sudaryti iš tarpusavyje sujungtų neuronų, sudarančių tinklą. Žemiau pateiktas 1 paveikslėlis iliustruoja dirbtinių neuroninių tinklų sandarą.




1 pav. Dirbtinių neuroninių tinklų sandara

Toliau einantys 3.1, 3.2 poskyriai detaliau apžvelgia dirbtinių neuroninių tinklų sudedamąsias dalis ir jų prasmę.

3.1. Neuronai

Neuronas dirbtiniuose neuroniniuose tinkluose yra pagrindinė sudedamoji - tai apdorojimo vietas (angl. „processing unit“), priimantis įvestį iš vieno neuronų ir generuojantis išvestį kitiems. Neuronai yra atsakingi už skaičiavimus, kurie padeda modeliui išgryninti sąryšį tarp duomenų įvesties ir numatomos išvesties. Šiai užduočiai atlikti neuronai pasitelkia svertinės sumos ir aktyvavimo funkcijas. Apie jas plačiau galima rasti atitinkamai 3.1.1 bei 3.1.2 poskyriuose.

Žemiau pateiktas 2 paveikslėlis iliustruoja neurono paskirtį dirbtiniuose neuroniniuose tinkluose.



2 pav. Neurono paskirtis dirbtiniuose neuroniniuose tinkluose

3.1.1. Svertinės sumos funkcija

Kaip jau buvo minėta neuronai tarpusavyje yra sujungti ir taip sudaro tinklą. Kiekviena jungtis tarp neuronų yra apibūdinama svoriu - skaitine reikšme, nusakančia, kokio dydžio įtaką vienas neuronas turi kitam. Šios reikšmės yra naudojamos svertinės sumos funkcijos reikšmei apskaičiuoti, kurios pavidalas yra

$$z = \sum_{i=0}^n x_i \cdot w_i + b$$

Čia z - svertinės sumos reikšmė, x_i - i -ojo neurono įvestis nagrinėjama neuronui, w_i - i -ojo neurono svoris, susijęs su nagrinėjamu neuronu, b - šališkumo (angl. „bias“) reikšmė.

Ši funkcija yra reikalinga tam, kad neuronas galėtų apibendrinti visas gautas įvestis į vieną skaitinę vertę, kuri vėliau perduodama aktyvavimo funkcijai, jei ji yra naudojama, arba kitam neuronų sluoksniui.

3.1.2. Aktyvavimo funkcijos

Dirbtiniai neuroniniai tinklai taikomi ne tik su tiesiniais, bet ir su netiesines savybes turinčiais duomenimis. Jei modeliai naudotų vien svertinės sumos funkcijos apskaičiavimus, jie generuotų tik tiesines išvestis ir nebūtų tinkami atpažinti sudėtingesnius duomenų raštus. Siekiant įveikti šį apribojimą, neuroniniuose tinkluose yra naudojamos aktyvavimo funkcijos.

Aktyvavimo funkcijos pasirinkimas labai priklauso nuo uždavinio specifikos. Žemiau esančiuose poskyriuose 3.1.2.1, 3.1.2.2, 3.1.2.3 yra pateikiamos dažniausiai dirbtiniuose neuroniniuose tinkluose naudojamos aktyvavimo funkcijos.

3.1.2.1. Sigmoidinė funkcija

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

3.1.2.2. Hiperbolinio tangento funkcija

$$f(x) = \tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$


3.1.2.3. Rektifikuoto tiesinio elemento funkcija

$$\text{ReLU}(x) = \begin{cases} 0, & \text{jei } x \leq 0 \\ x, & \text{jei } x > 0 \end{cases}$$

3.2. Sluoksniai dirbtiniuose neuroniniuose tinkluose

Dirbtiniai neuroniniai tinklai išsiskiria nuo kitų mašininio mokymosi metodų savo architektūra - neuronų tinklas yra sudarytas sluoksniais. Dažniausiai dirbtinius neuroninius tinklus sudaro vienas įvesties, vienas ar keli paslėptieji ir vienas išvesties sluoksnis.

Žemiau pateiktas 3 paveikslėlis iliustruoja dirbtinių neuroninių tinklų sandarą atsižvelgiant į neuronų sluoksnius.



3 pav. Dirbtinių neuroninių tinklų sluoksniai

3.2.1. Įvesties sluoksnis

Įvesties sluoksnis dirbtiniuose neuroniniuose tinkluose yra atsakingas už duomenų surinkimą. Neuronų skaičius šiame sluoksnyje priklauso nuo to, kokios dimensijos duomenys yra nagrinėjami, neįskaitant klasės ar spėjamos reikšmės. Taip, pavyzdžiui, turint duomenis su dviem požymiais, įvesties sluoksnyje bus du neuronai. Tuo tarpu turint šešių dimensijų duomenis, neuronų įvesties sluoksnyje bus šeši.

3.2.2. Išvesties sluoksnis

Išvesties sluoksnis dirbtiniuose neuroniniuose tinkluose yra naudojamas modelio rezultatams generuoti. Neuronų kiekis šiame sluoksnyje priklauso nuo sprendžiamos užduoties tipo. Klasifikavimo uždaviniuose išvesties sluoksnio neuronų skaičius paprastai sutampa su galimų klasių skaičiumi, o kiekvieno neurono išvestis interpretuojama kaip tikimybė, kad įvesties duomenys priklauso tai klasei. Tuo tarpu regresijos uždaviniuose dažniausiai naudojamas vienas neuronas, kurio išvestis atitinka prognozuojamą reikšmę.

3.2.3. Paslėptasis sluoksnis

Paslėptieji sluoksniai dirbtiniuose neuroniniuose tinkluose yra skirti matematinių ryšių tarp įvesties ir išvesties nustatymui. Šiuose sluoksniuose esančių neuronų kiekis yra hiperparametras - jis yra parenkamas eksperimentiškai, analizuojant, su kokia reikšme modelis pasirodo geriausiai validacijos metu.

4. Duomenų aibės kūrimas

4.1. Dirbtinis duomenų generavimas

Dirbtinis duomenų generavimas - tai duomenų kūrimas, naudojant programinius algoritmus, siekiant atkartoti realaus pasaulio duomenų statistines savybes.

Dirbtinai sugeneruoti duomenys leidžia užtikrinti didelį duomenų kiekį bei jų įvairumą. Dėl šios priežasties šis duomenų kūrimo būdas yra plačiai naudojamas tais atvejais, kai realaus pasaulio duomenų yra per mažai, arba kai jie yra sunkiai prieinami dėl finansinių priežasčių.

Be to dirbtinis duomenų generavimas yra naudingas situacijose, kai dirbama su duomenimis, reguliuojamais asmens duomenų apsaugos įstatymais. Tokiuose atvejuose sintetiniai duomenys leidžia išvengti jautrių duomenų nutekėjimo, kadangi modelių apmokymui nėra naudojami su konkrečiais asmenimis susiję duomenys.

Kitas scenarijus, aktualus ir šio kursinio kontekste, yra kai duomenys neprivalo turėti kažkokio konkretaus domeno. Pavyzdžiui, tiriant mašininio mokymosi metodų savybes yra pravartu modelius išbandyti su skirtingo pobūdžio duomenimis. Tad dirbtinis duomenų generavimas suteikia galimybę lengvai sugeneruoti didelį kiekį įvairias savybes turinčių duomenų.

Šiame darbe duomenys buvo generuojami dirbtinai, pasitelkiant sferos, ... etalono funkcijas (angl. „benchmark functions“). Jos yra aprašomos atitinkamai 4.1.1, ?? bei ?? poskyriuose.


4.1.1. Sferos funkcija

Sferos funkcija yra viena iš paprasčiausių etalono funkcijų, kurios pavidalą galima rasti žemiau pateiktoje 1 formulėje.

$$f(X) = \sum_{i=0}^n x_i^2 \quad (1)$$

Čia x_i yra vektoriaus X komponentės, o n duomenų dimensijos dydis.

Šios funkcijos grafikas yra simetriškas ir pasižymi išgaubtumu. Žemiau pateiktas 4 paveikslėlis atvaizduoja sferos funkcijos grafiką dvimačiu atveju.



4 pav. Sferos funkcijos generuojamų duomenų grafikas

4.2. Triukšmo duomenų aibei pritaikymas

Dirbant su realaus pasaulio duomenimis dažnai susiduriama su tuo, kad jie nėra visiškai tikslūs. To priežastys gali būti įvairios - žmogaus klaidos, prietaisų tikslumo ribos, aplinkos veiksnių poveikis ir t.t. Tokie nedideli netikslumai duomenyse yra vadinami triukšmu.

Kadangi realaus pasaulio sąlygomis surinkti duomenys retai būna tikslūs, mašininio mokymosi metodai turi gebėti gerai dirbti su duomenimis, kuriuose yra triukšmo. Dėl šios priežasties apmokant mašininio mokymosi modelius su dirbtinai generuotais duomenimis, taip pat yra duomenims pridėti tam tikrą triukšmo lygį.


4.2.1. Gauso skirstinio metodas

Vienas iš triukšmo pridėjimo būdų pasitelkia Gauso skirstinį.

Žemiau pateiktuose paveikslėliuose galime pamatyti, kaip σ triukšmo parametro dydis lemia taškų išsidėstymą.


Žemiau pateiktame paveikslėlyje matome triukšmo pritaikymo pavyzdį dvimatėje erdvėje.

Švarių duomenų ir duomenų su triukšmu sugretinimas



5 pav. Švarių ir duomenų su triukšmu sugretinimas, kai ...

Švarių duomenų ir duomenų su triukšmu sugretinimas



6 pav. Švarių ir duomenų su triukšmu sugretinimas, kai ...

Šio kursinio kontekste paklaidos buvo generuojamas pasitelkiant normalųjį skirstinį, kur paklaidos vidurkis yra 0, o standartinis nuokrypis 0.5.

Išvados

TODO